

99221 למידה מרובת סוכנים · פרויקט סופי

PSRO על Kuhn Poker

Policy-Space Response Oracles

האם אוסף של שחקנים עמיד יותר מאימון נגד עצמך, באותו תקציב?

נדב פיירמן

התשובה: כן, פי 39.7

1.2500


אימון נגד עצמך: כמה יריב שמכיר אותו מרוויח נגדו

0.0315

PSRO: אותו תקציב אימון, אותו משחק

המדד נקרא exploitability: כמה יריב ירוויח נגדנו אם ידע בדיוק איך אנחנו משחקים. אפס אומר שאין מה לנצל. כאן הוא מחושב, לא מוערך.

מה זה exploitability, בתמונה אחת



0.5833


לומד אימון-עצמי: יריב מושלם מרוויח נגדו יותר
מאשר מול שחקן אקראי

-0.0556

שיווי משקל: יריב מושלם מקבל רק את ערך
המשחק, אין מה לנצל


exploitability אפס פירושו שאין נקודת תורפה. זה מה שהמפרט מבקש למדוד.

הבעיה: אין שחקן שמנצח את כולם



כמו אבן-נייר-ומספרים. באוסף שנלמד כאן נמצאו עשרה מעגלים כאלה.

- אימון עצמי: שחקן אחד, שמחולף בכל סבב
- כל מחליף מפסיד למי שהיה לפניו — מעגל
- PSRO זוכר את כל הגרסאות ומאמן נגדן



הלמידה עוברת מרמת הפעולה לרמת המדיניות: לא איזו פעולה לבחור, אלא איזה שחקן לשחק.

למה Kuhn Poker: משחק קטן שאפשר לפתור במדויק

שלוש בדיקות שיצאו מדויקות

- חמישה פתרונות מהמשפחה: ערך $1/18$ - ו- exploitability אפס
- שני מספרים שספריית OpenSpiel מפרסמת: $11/12$ ו- 2
- ארבעה משחקים שפתרונם ידוע, לבדיקת הפותרים

- שלושה קלפים, אסימון לקופה, הימור של אסימון, וחמישה מהלכי משחק
- שש מצבים להחליט בהם, ולכן 64 דרכי משחק. אפשר לעבור על כולן
- ולכן exploitability כאן מחושב במדויק, לא מוערך
- יש פתרון מתמטי ידוע: משפחה שלמה לשחקן הראשון, פתרון יחיד לשני

המספרים האלה לא נקבעו כאן. אי אפשר לכוון אליהם בטעות — ושלושתם יוצאים בדיוק מכונה.

איך זה בנוי: שישה שלבים בכל סבב

1 השלמת החסר בטבלת מי-מנצח-את-מי

2 חישוב התערובת מתוך הטבלה

3 אימון שחקן חדש נגד תערובת היריב

4 הוספתו לאוסף

5 רישום exploitability, אנטרופיה וערך

6 שמירה, כדי להמשיך ריצה שנקטעה

3 אורקלים

Q-learning, REINFORCE
ותגובה מיטבית מדויקת, כולם
מאפס

8 פותרים

המפרט דורש שלושה; בחירת
הפותר היא בחירת האלגוריתם


131 ריצות

חמישה seeds לכל ניסוי, כל
ריצה עם קובץ פרמטרים

89 בדיקות

חוקי המשחק, הפתרון האנליטי,
הפותרים, הלולאה ושחזור

ניסוי 1: אימון נגד עצמך מול PSRO, אותו תקציב



פי 39.7

פחות ניתן לניצול: 0.0315 מול 1.2500



פי 13

פחות מפסיד לגרסאות מוקדמות של עצמו

1.17 מול 0.00

אנטרופיה: PSRO מגריל בין כמה שחקנים, אימון עצמי נעול על אחד

המחיר: אימון עצמי מנצח חלשים, ומנוצל בעצמו



-0.0556

PSRO מול הפתרון המתמטי: בדיוק ערך המשחק


-0.4167 מול -0.0326

מול גרסאות מוקדמות שלו הוא קורס

0.4347 מול 0.1001

מול יריבים חלשים אימון עצמי מרוויח יותר

ניסוי 2: שמונה דרכים לחשב את התערובת



3 ראשונים

fictitious play, נאש ו-regret matching; רווחי הסמך חופפים

5 מתוך 8


האוסף כבר מכיל פתרון מלא; ההבדל בשקלול, לא באיסוף

0.5178

rectified Nash, גרוע אפילו מחלוקה אחידה

ניסוי 3: מה יש באוסף

Exact payoff matrix; the four policies with weight outlined



4 מתוך 13

שחקנים שקיבלו משקל בתערובת הסופית


10 מעגלים

3.5 אחוז מהשלשות; אין שחקן שמנצח את כולם, ולכן הפתרון חייב להיות תערובת

0 מול 2

שחקנים נשלטים: לראשון אין, לשני שניים, כמו בפתרון המתמטי

הראיה החזקה ביותר: השחקן נחת על הפתרון המתמטי




המשקלים בתערובת הם פרמטרי הפתרון

- $\beta = 0.3322$, תשלום עם המלכה
- $\gamma = 0.0799$, הימור עם המלך
- $\alpha = 0.0361$, בלוף עם הנסיך
- כל פעולה חופשית אצל שחקן אחד בלבד, ולכן משקלו הוא התדירות
- מרחק 0.0372 מהמשפחה; לשחקן השני 0.0533

אף מודול אימון אינו מזכיר את הפתרון הזה. PSRO מצא אותו לבד, כולל הבלוף שהוא מחייב.

מה השחקן שנלמד עושה בשולחן: 5,000 ידיים

Where the game value comes from: 5,000 hands



84%


מהידיים נגמרות בלי הימור יזום: check משני הצדדים, או קיפול

1.2%

בלוף. מפסיד 0.95 ליד, ובלעדיו הימור הערך לא היה מרוויח

סך התרומות -0.0646, במרחק רעש דגימה מערך המשחק 1/18.-

ניסוי 4: מאיפה מגיעה השגיאה שנשארת



5.55e-17


בלי אימון ובלי דגימה: אפס, בתוך 0.23 שניות

0.0128 + 0.0153

מחיר הדגימה ותוספת האימון: כמעט שווים, יחד
0.0281

האימון בולע 1.2 מיליון משחקים, ובכל זאת אינו הרכיב הכבד.

אבלציות: מה עושה את העבודה



אוכלוסייה מופרד פי 39.67

חישוב התערובת מופרד פי 4.64


דיוק ההערכה על הגבול פי 2.50

חוזק המאמן ברעש פי 1.36

התחלה היוריסטית ברעש פי 0.70

מה שחשוב: האוכלוסייה, והתערובת שפותרת אותה. לא חוזק הלומד.

הרחבת בונוס: Rectified PSRO, ושחזור כשל מתועד



5.4 מתוך 13

שחקנים שונים מתוך אלה שהוסיף; השאר עותקים

0.5178

גרוע אפילו מחלוקה אחידה, והאוסף בלי פתרון

השיטה פותחה למשחקים סימטריים ו-Kuhn אינו כזה: גבול תחולה, לא הפרכה.

מגבלות, ומסקנה

מגבלות

- משחק קטן: בסביבות גדולות ה-exploitability עצמו מוערך בקירוב
- חמישה seeds לא מפרידים בין שני הפותרים המובילים
- ההתכנסות המהירה היא תכונה של Kuhn; יש משחקים שדורשים מספר סבבים מעריכי
- רפליקטור מחזיר סבב אחרון; סף העצירה נקבע לאפס בכוונה

כ.


אוסף שחקנים שמחשבים איך לשלב ביניהם עמיד פי 39.7 מאימון נגד עצמך, מגיע לערך הנכון של המשחק, לא מסתובב במעגל, ונוחת על הפתרון המתמטי בלי ששום דבר בקוד רמז עליו.

המחיר: מול יריבים חלשים אימון עצמי מרוויח יותר. עמידות ויכולת ניצול אינן אותו דבר.



שאלות

נספח א: אימות המדידה, והקוד



24 מתוך 25

תאים שבהם הערך האמיתי נופל
בתוך רווח הסמך

0.0875

השגיאה הגדולה ביותר

כל תא: חמישה בלוקים של 400
משחקים; רווח t במכפיל 2.776
ולא 1.96, כי המדגם קטן.

game.py עץ המשחק, שחקנים,
הרצות

exact.py החישוב המדויק

metagame.py טבלת מי-מנצח-את-מי

oracles.py שלושת המאמנים

metasolvers.py שמונה פותרים


psro.py הלולאה, שמירה והמשך

analysis.py גיוון, סטטיסטיקה, גרפים

experiments.py ניסויים, אבליציות, CLI

test_psro.py 89 בדיקות

נספח ב: תעודת ההתכנסות





שני חסמים על ערך המשחק

- חסם עליון: שחקן 1 כלוא באוסף, שחקן 0 חופשי במשחק המלא
- חסם תחתון: להפך
- ההפרש הוא population exploitability: לא תלוי בפתור
- אפס אינו קירוב: האוסף מכיל פתרון של המשחק המלא

זה תנאי העצירה של double oracle, לפי McMahan ואחרים משנת 2003.

נספח ג: תקציב האימון, ולאן הולכות האפיזדות



משמאל: פי 100 תקציב אימון משפר את הממוצע ב-0.015, אך מוריד את סטיית התקן מ-0.036 ל-0.011. מימין: מסבב 5 הערכת הטבלה עוקפת את האימון.